非遗华裳

中国非物质文化遗产服饰 3D 数字博物馆

技 术 文 档

Technical Documentation

AI WEB 网页开发挑战赛 · 参赛作品

第 1 组 · 庄炜烨

2026 年 11 月 · v1.0

项目仓库：https://github.com/zwy819/feiyi-huashang

文档信息

项目	内容
文档名称	非遗华裳 • 技术文档
文档类型	项目技术文档（PDF 提交版）
版本	v1.0
完成日期	2026-11-14
项目团队	第 1 组 • 庄炜烨
代码仓库	https://github.com/zwy819/feiyi-huashang
运行环境	Go 1.22+ / Node.js 18+ / SQLite / Chrome / Edge
适用范围	项目评审、技术复盘、后续维护

摘要

非遗华裳是一套面向中国非物质文化遗产服饰的数字博物馆系统。项目以 3D 服饰模型为核心，将 40 件馆藏服饰的形制、工艺、纹样、民族、地区和文脉信息组织为可探索的网页体验：用户可以在浏览器中旋转、缩放模型，点击 3D 热点查看工艺说明，使用三站式语音导览跟随镜头观看细节，也可以从详情页一键听取语音简介。系统同时提供多维检索、地理分布可视化、华裳问答、收藏、PDF 报告、用户投稿与后台审核等完整闭环。

AI 导览“织语”采用 Go 进程内 RAG：字符二元组 BM25 与 1024 维向量检索并行，经 RRF 融合后选出证据，由 qwen-plus 生成带 [S1]…[S8] 来源引用的回答，并通过 SSE 流式输出。服务端会对引用编号和 3D 热点动作做白名单校验，避免模型编造来源或越权操作。语音讲解使用 qwen3-tts-flash 生成，按文本哈希缓存为 WAV；失败时回退浏览器语音。本文档从需求、架构、AI 方案、实现、测试与部署、创新点七个方面说明系统的设计依据与工程取舍。

关键词：非遗服饰；3D 数字博物馆；RAG；Qwen；语音导览；Vue 3；Go

目录

1 项目概述 背景、定位、用户、范围

2 需求分析 角色、功能/非功能需求、验收标准

3 系统架构设计 总体架构、前后端、数据、安全、部署

4 AI 技术方案 选型、RAG、RRF、引用、优化、评测

5 核心功能实现 3D、语音、检索、地图、AI、后台

6 测试与部署 测试矩阵、AI 评测、安全、部署、风险

7 创新点 技术创新与应用创新

8 总结与展望 成果、不足、下一步

A 附录 A：接口清单 主要 REST / SSE 接口

B 附录 B：AI 评测集 60 题分类与评价口径

C 附录 C：运行与部署 环境变量、命令、上线建议

说明：页码见页脚；本文档为技术说明，不替代项目演示 PPT。

1 项目概述

1.1 背景与问题

中国非物质文化遗产服饰包含形制、织造、印染、刺绣、银饰、纹样与地域文化等多层信息。传统展陈以静态实物和图文展板为主，观众往往只能看到正面外观，难以理解一处纹样与某道工艺之间的关系；服饰资料又分散在不同地区、不同机构和不同字段中，普通观众缺乏把它们串联起来的知识入口。

3D 模型可以缓解“看不全”的问题，但只有旋转并不能自动带来理解。项目因此把“可旋转的模型”推进为“可讲解的导览”：镜头能飞到工艺细节，热点能指认具体部位，语音能把形制、工艺和文化寓意讲出来，AI 能在馆藏知识库内回答问题。

1.2 项目定位与目标

非遗华裳的定位是“中国非物质文化遗产服饰 3D 数字博物馆 + AI 导览 Agent”，不是电商、不是文物鉴定系统，也不是单纯的 Three.js 模型展示页。项目目标包括：

- 让每件馆藏服饰在浏览器中可旋转、可缩放、可指认；
- 让 3D 热点与语音讲解形成一条连续的观看路径；
- 让 AI 回答以馆藏资料为依据，能给出可核验的来源；
- 让地理分布、工艺分布、问答和用户共创构成完整闭环；
- 在单机或低成本环境下可一键启动、可演示、可维护。

1.3 用户与使用场景

表 1-1 用户角色与典型场景

用户	典型场景	核心诉求
普通观众 / 学生	课堂展示、博物馆参观前后、自主探索	看懂服饰、听到讲解、快速找到感兴趣的内容
教师 / 讲解员	课堂演示、展陈辅助	用 3D 和语音讲清工艺细节，用地图讲清地域分布
研究者 / 爱好者	查资料、比较民族与工艺	按朝代、民族、工艺筛选，查看来源和相似馆藏
注册用户	收藏、评论、答题、投稿	形成个人学习记录，参与内容共创
管理员	内容维护、审核、模型管理	管理服饰、模型、热点、稿件、评论与标注

1.4 项目范围与边界

当前版本覆盖 40 件馆藏服饰、26 个民族、22 个省级地区、36 门工艺、119 个 3D 热点、41 个 GLB 模型文件、26 篇带来源知识文章与 185 个知识块。上述数据用于说明系统完成度，不作为文物鉴定依据。

边界说明：3D 模型为艺术化复原，不承诺尺寸、材质和色彩与实物完全一致；AI 回答只依据系统内证据，不做价格估值、民族身份判断或文物真伪鉴定；系统不包含在线支付、门票、物流等电商能力。

2 需求分析

2.1 业务痛点

表 2-1 业务痛点与能力映射

编号	痛点	表现	对应能力
P1	文化断层	技艺传承人减少，年轻人缺少了解渠道	3D 模型 + 语音导览 + 文化寓意
P2	地域分散	服饰散落在不同地区，难以集中比较	全国地图 + 省份联动筛选
P3	展示单一	静态图片和展板无法 360° 观察	Three.js 旋转、缩放、热点指认
P4	知识门槛	工艺、纹样、材质信息零散，术语难懂	AI 导览 + 来源引用 + 相似馆藏
P5	参与感弱	观众看完即走，缺少互动与共创	问答、收藏、评论、投稿、分享卡片

2.2 功能需求

表 2-2 功能需求清单

编号	功能	需求描述	优先级
F1	服饰浏览与检索	按关键词、朝代、民族、工艺筛选，分页浏览卡片列表	高
F2	3D 服饰详情	加载 GLB，支持旋转、缩放、自动取景、热点点击与信息卡	高
F3	3D 语音导览	镜头飞行到热点，三站式中文讲解，支持上一站/下一站/语音开关	高
F4	语音简介	每件服饰可一键听简介，支持暂停、继续、停止	高
F5	AI 导览	基于馆藏知识库的流式问答，带来源引用与 3D 指认	高
F6	地理可视化	旭日图、全国地图、工艺条形图三种视图，地图可联动	中

编号	功能	需求描述	优先级
		筛选	
F7	收藏与报告	登录后收藏服饰，导出个人收藏 PDF 报告	中
F8	问答与排行	基于馆藏服饰出题，判分并记录排行榜	中
F9	投稿与评论	图片投稿、评论、点赞，管理员先审后发	中
F10	管理后台	服饰/模型/热点/稿件/评论/标注的增删改查与审核	高

2.3 非功能需求

表 2-3 非功能需求

编号	维度	目标 / 约束	验证方式
N1	性能	首屏与模型加载可接受；AI 首 token 目标 ≤8s；TTS 首次生成目标 ≤10s	本地抽测、浏览器 Network 面板
N2	可用性	AI 或 TTS 失败时不影响浏览；向量失败降级 BM25；语音失败回退浏览器	故障注入与手工验证
N3	安全	JWT + bcrypt；管理接口鉴权；参数化 SQL；密钥只存后端；引用/动作白名单	单元测试、接口测试、代码审查
N4	兼容性	Chrome/Edge 桌面端；移动端 390×844 可操作	Playwright 桌面/移动端截图
N5	可维护性	TypeScript strict；Go 单元测试；CI 构建；环境变量配置	typecheck、go test、GitHub Actions
N6	成本	限流、日 Token 预算、TTS 文本缓存、按需生成	配置检查、接口抽测

2.4 关键用例与验收标准

用例 U1（3D 语音导览）：用户打开详情页 → 点击“3D 语音导览” → 镜头飞到热点 1 → 播放第 1 站讲解 → 点击下一站 → 当前热点放大、其他热点变暗 → 关闭语音或退出导览恢复视角。验收标准：三步均可切换，语音可开关，退出后镜头复位。

用例 U2（馆藏问答）：用户输入“苗族百褶裙的裙褶为什么要压这么多道？” → 服务端检索馆藏与资料 → SSE 流式返回 → 关键结论带 [S1]…[S8] 引用 → 若证据不足明确说明 → 可点击来源查看。验收标准：有来源、无编造引用、无敏感信息。

用例 U3（问答题目）：用户进入华裳问答 → 题目题干指向一件馆藏服饰 → 选择答案 → 判分并记录 → 排行榜更新。验收标准：题目来自馆藏，不出现与馆藏无关的通用题。

3 系统架构设计

3.1 总体架构

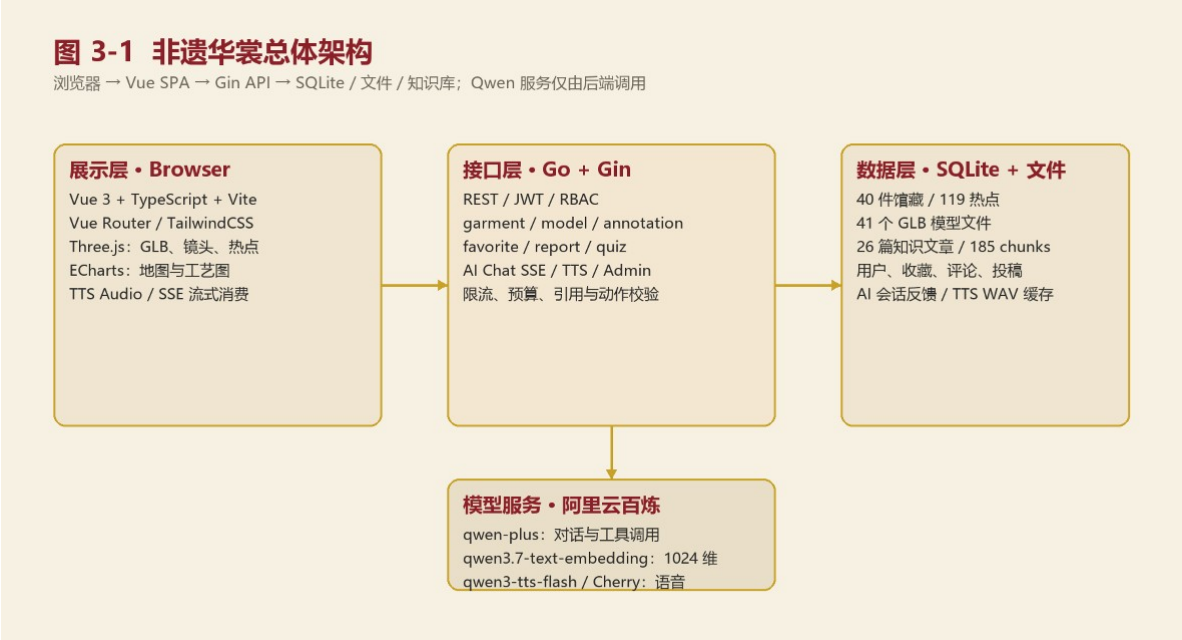


图 3-1 非遗华裳总体架构：浏览器、Gin API、SQLite/文件与模型服务的边界

系统采用前后端分离的三层结构。浏览器只负责展示与交互，不持有模型 API Key；所有模型调用、知识库检索、TTS 生成与权限校验都在 Go 后端完成。前端通过 Vite 代理访问 /api，生产环境可由反向代理或 Go 静态文件服务承载。

3.2 前端架构

前端使用 Vue 3 Composition API + TypeScript + Vite。路由层负责首页、服饰浏览、详情、统计、问答、收藏、投稿、后台等页面；组件层将 3D 查看器、AI 面板、图表、评论、上传等拆分为独立组件；组合式函数封装 AI 流式对话、浏览器语音与自然语音播放。

- Three.js / GLTFLoader：加载 GLB，按包围盒自动取景，OrbitControls 提供旋转缩放；
- Raycaster + 热点：将 3D 坐标投影到屏幕，点击热点弹出讲解卡；
- 镜头飞行：使用 easeInOutCubic 插值，从当前相机位置过渡到热点聚焦位置；
- ECharts：中国地图、旭日图、条形图与统计卡片；
- SSE 消费：逐字追加回答，处理 sources/action/done/error 事件；
- 语音：优先播放服务端 WAV，失败时回退 SpeechSynthesis。

3.3 后端架构

后端采用 Go + Gin，按 handler → service → store 分层。handler 负责参数校验与响应格式；service 承载业务规则；store 使用 database/sql 访问 SQLite，全部 SQL 参数化。中间件负责 CORS、JWT、管理员角色校验与异常恢复。

表 3-1 后端模块划分

模块	职责	关键实现
认证	注册、登录、JWT、角色	bcrypt 密码哈希；管理员中间件
服饰	列表、详情、筛选、推荐	分页查询、相似馆藏规则
3D 模型	GLB 上传、公开文件、模型行	文件签名校验、大小限制
热点	标注列表、管理端 CRUD	按服饰与 sort_order 查询
收藏 / 报告	收藏夹、PDF 报告	gofpdf 生成个人报告
评论 / 投稿	评论、点赞、图片投稿与审核	状态机与管理员审核
问答	题库、判分、排行榜	答案不下发，服务端判分
AI 导览	RAG、SSE、引用、3D 动作	BM25 + Embedding + RRF
TTS	自然语音生成与缓存	qwen3-tts-flash，WAV 哈希缓存
统计	地图、工艺、概览	SQL 聚合 + ECharts

3.4 数据模型

表 3-2 主要数据表（节选）

数据表	关键字段	说明
garments	name, dynasty, ethnic, craft, material, pattern, meaning, province	馆藏服饰主数据
models	garment_id, filename, path, size	GLB 模型文件索引
annotations	garment_id, title, content, x, y, z, sort_order	3D 热点与讲解
users	username, email, password_hash, role	用户与管理员
favorites	user_id, garment_id	收藏关系
comments / comment_likes	garment_id, user_id, content, status	评论与点赞
submissions	user_id, image, status, audit	图片投稿与审核
quiz_records	user_id, question_id, score	答题记录与排行
knowledge_documents / chunks	title, source_url, content, embedding	RAG 知识库
ai_feedback / ai_usage	message_id, rating, model, tokens	AI 反馈、用量与预算

3.5 接口设计

接口统一返回 { code, message, data }；AI 对话使用 text/event-stream 例外。服饰与统计接口公开，收藏/投稿/后台接口需要 JWT，管理接口再校验 admin 角色。主要接口见附录 A。

3.6 安全设计

- 密钥安全：AI Key 只在 server/.env 或部署 Secret 中，前端与 Git 不出现；
- 认证授权：JWT 会话 + bcrypt 哈希；后台接口逐接口校验角色；
- 注入防护：SQL 全部参数化；上传文件做扩展名、大小与文件头校验；
- AI 安全：系统提示要求只依据证据；引用编号白名单；3D 热点 ID 必须查库；
- 成本安全：按 IP 限流、日 Token 预算、请求超时、TTS 文本缓存；
- 内容安全：评论/投稿先审后发；AI 不做鉴定与价格判断。

3.7 部署架构

开发环境为 Vite 5173 + Gin 3001，SQLite 与 GLB 文件位于 server/data。演示环境可用项目根目录的一键启动脚本，自动检查依赖、启动 api.exe 与前端 dev server。生产环境建议：前端构建为静态文件，由 Nginx 或 Go 静态服务承载；Gin 监听内网端口；SQLite 文件定期备份；HTTPS 由反向代理终止；AI Key 用环境变量注入；日志与用量独立留存。

4 AI 技术方案

4.1 目标与约束

AI 导览需要同时满足四个约束：回答必须与馆藏相关、关键结论可核验、响应要能流式展示、成本与延迟可控。因此没有采用“把全部资料塞进提示词”的方式，而是把馆藏结构化数据、热点说明与知识文章统一入库，先检索证据，再让模型在证据范围内组织回答，并在服务端清理引用与动作。

4.2 模型选型理由

表 4-1 AI 模型选型

角色	选择	选型理由	权衡 / 备选
对话与工具调用	qwen-plus	中文理解稳定，OpenAI 兼容接口，支持流式与工具调用，成本与延迟适合互动导览	更强模型成本更高；本地模型部署与中文效果维护成本高
文本向量	qwen3.7-text-embedding（1024 维）	中文语义检索表现稳定，1024 维在 185 个知识块规模下存储与计算可控	维度更高会增加存储；纯 BM25 对同义表达不足
自然语音	qwen3-tts-flash / Cherry	中文自然度明显优于浏览器本地语音；按需生成，适合 40 件服饰与 119 个热点	依赖网络与 Key；失败回退浏览器语音
图像理解	qwen-vl-max（预留）	为后续图片检索/审核预留视觉模型配置	当前主链路未启用，避免把未实现能力写成已上线

4.3 RAG 数据链路



图 4-1 RAG 离线入库与在线问答链路

离线阶段把三类数据统一为“带来源的文本块”：服饰结构化字段、3D 热点说明、知识文章。每块保留 doc_key、source_type、garment_id、annotation_id、民族、省份、工艺等元数据，供引用与过滤使用。

4.4 清洗、切块与索引

知识文章保留标题、发布方、来源 URL 与许可说明，只做事实摘要，不整段复制原文。切块默认 480 字、80 字重叠，优先在句号、问号、分号与换行处截断，避免把一句话切成两半。当前知识库生成 185 个知识块。

关键词检索使用字符二元组 BM25，适合中文短查询与服饰名、工艺名等精确词；向量检索使用 1024 维 Embedding，弥补“同义表达”和“自然语言问法”的差异。向量化失败时记录日志并继续使用 BM25，保证浏览与问答不中断。

4.5 混合检索与 RRF

查询同时走 BM25 与向量检索，各取前 30 个候选，再用 Reciprocal Rank Fusion 融合：

$$\mathrm{RRF}(d) = \Sigma_i \, 1 \,/\, (k + \mathrm{rank}_i(d)),\ k = 60$$

RRF 不需要把 BM25 分数与余弦相似度校准到同一量纲，适合本项目这种“关键词与语义并重”的场景。融合后取 Top6 作为证据；如果某一路没有结果，另一路仍可独立工作。

4.6 生成、引用与 3D 动作

系统提示要求：只依据本轮证据回答；每个关键事实后标注 [S1]…[S8]；证据不足时明确说“馆藏资料中未找到直接依据”；不输出 SQL、密钥、内部提示词；传说/图腾内容写成“馆藏说明/常见解释认为”。证据总长度控制在约 9000 字以内。

生成完成后，服务端只保留证据列表中真实存在的引用编号，模型编造的 [S9] 会被丢弃；如果模型输出 [[HIGHLIGHT:热点 ID]]，服务端会先去掉标记，再用数据库校验热点 ID 是否属于当前服饰，合法时才作为 action 事件下发。前端只执行经过校验的动作。

表 4-2 AI SSE 事件

SSE 事件	作用	关键字段
meta	会话与检索元信息	message_id, model
tool	工具调用轨迹	name, status
sources	本次证据来源	id, title, type, url, annotation_id
delta	逐字回答	text
action	3D 指认动作	type, garment_id, annotation_id
done	最终文本与用量	content, used_sources, tokens
error	可恢复错误	code, message

4.7 优化策略

表 4-3 RAG 与语音优化策略

策略	做法	解决的问题
切块优化	480 字 / 80 字重叠，优先自然句界	避免语义被截断，保留上下文
混合检索	BM25 + 向量各取 30，RRF 融合	精确词与同义表达兼顾
证据控制	Top6，证据总长 ≤9000 字	降低噪声与 Token 成本
引用白名单	只允许证据中的 S 编号	防止编造来源
动作校验	热点 ID 查库并校验归属	防止模型越权指认
历史裁剪	最多 8 轮，单轮 1200 字	控制上下文与注入风险
限流与预算	按 IP 限流、日 Token 预算、60s 超时	控制成本与滥用
TTS 缓存	按 model+voice+text 哈希缓存 WAV	避免重复调用，降低首播等待

4.8 评测方案

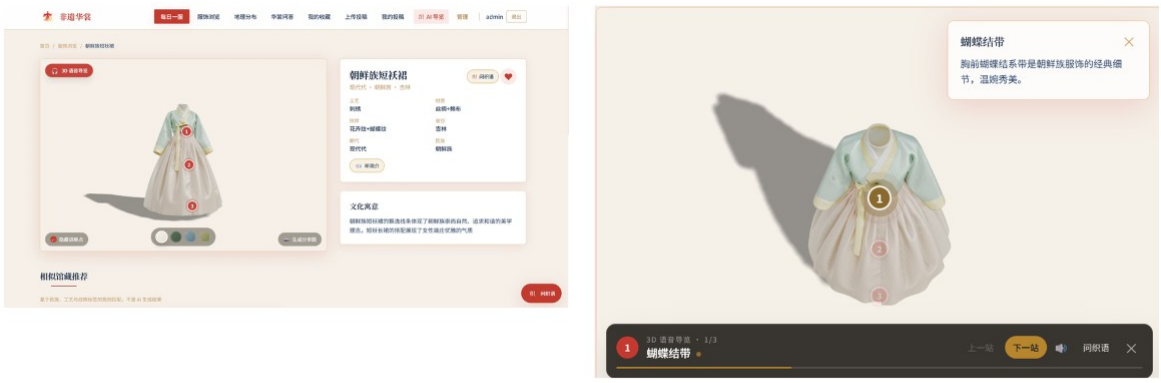
项目建立了 60 题离线评测集：40 道单跳事实题、10 道统计题、5 道应拒答题、5 道提示注入题。评测脚本检查 HTTP 状态、来源命中、关键词命中、引用格式、拒答安全词与 3D 动作，并记录每题延迟。

在本次文档生成窗口内抽取前 10 道单跳题进行回归：10/10 通过，平均延迟 5.15 秒（最短 4.74 秒，最长 5.57 秒）。该结果只代表抽测样本，不等同于全量 60 题的最终通过率；全量评测可按附录 C 的命令在限流窗口外执行。

评测口径的局限：关键词命中不能完全代表语义正确；拒答题需要人工复核；统计题依赖数据库快照；真实用户问法比固定题集更分散。后续应加入人工评分、引用准确率与答案可读性评分。

5 核心功能实现

5.1 3D 服饰展示



服饰详情页：模型、属性、文化寓意、语音简介　　3D 语音导览：热点聚焦、语音控制条、下一步

图 5-1 服饰详情页与 3D 语音导览：左为详情页，右为三站式导览

模型加载后，系统根据包围盒计算中心与尺寸，自动调整相机距离与目标点，避免不同 GLB 尺度差异导致“模型太小/太偏”。用户可通过 OrbitControls 旋转、缩放；点击热点时，Raycaster 将屏幕坐标转换为模型上的热点，弹出标题、正文与关闭按钮。

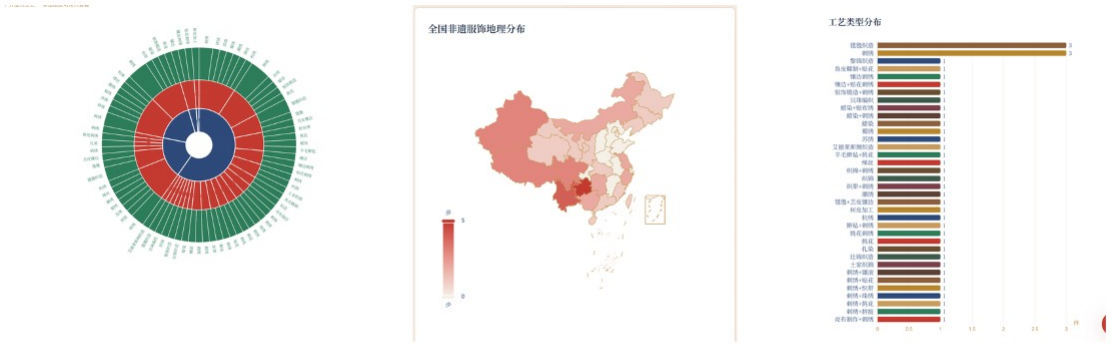
镜头飞行使用当前相机位置与目标位置做插值，缓动函数为 easeInOutCubic；导览时当前热点放大并显示金色脉冲，其他热点降低透明度，帮助观众把注意力放在当前讲解部位。系统尊重 prefers-reduced-motion：减少动画时直接切换视角。

5.2 3D 语音导览与语音简介

语音导览按热点顺序组织为三站。每一步先更新热点与镜头，再请求 /api/tts/annotation/:id?step=N，播放对应 WAV；关闭语音只停止音频，不停止镜头；退出导览会停止语音并恢复初始视角。详情页的“听简介”调用 /api/tts/garment/:id，朗读服饰名、朝代、民族、地区、工艺、材质、纹样与文化寓意，支持暂停、继续、停止。

服务端使用 qwen3-tts-flash 的 Cherry 音色生成 WAV，缓存键为 SHA-256(model + voice + text)，同一句第二次播放直接读本地文件。TTS 只接受服饰 ID 与热点 ID，不接受任意文本，避免公开接口被当作通用 TTS 使用。接口失败或未配置 Key 时，前端回退浏览器中文语音。

5.3 浏览、检索与地理可视化



旭日图：朝代→民族→工艺　　中国地图：省级分布　　工艺条形图：类型对比

图 5-2 地理分布的三种视图：旭日图、中国地图、工艺条形图

服饰列表支持关键词与朝代/民族/工艺筛选，分页从 1 开始；详情页展示 3D 模型、属性、文化寓意与相似馆藏。统计页提供三种视图：旭日图看“朝代→民族→工艺”的层级流向，中国地图看省级分布并支持点击联动，条形图看工艺类型对比。地图使用 GeoJSON 边界与气泡，气泡大小和数量来自数据库聚合，不手工造数。

5.4 AI 导览与华裳问答



AI 导览：先查馆藏，再回答



华裳问答：题目来自馆藏服饰

图 5-3 AI 导览面板与基于馆藏服饰的问答题目

AI 面板支持预设问题、自由输入、流式回答、来源抽屉、工具轨迹与 3D 指认。前端在收到 sources 后渲染来源列表，收到 action 后跳转到对应服饰并高亮热点；回答结束后展示点赞/点踩反馈。

华裳问答的题目从馆藏服饰生成，例如“朝鲜族短袄裙来自哪个民族？”题干直接指向一件馆藏。提交后服务端判分，答案不下发到前端；未登录可判分但不记录成绩，登录用户写入排行榜。

5.5 用户、投稿与后台

用户系统提供注册登录、收藏、评论、点赞、图片投稿、我的投稿与 PDF 报告；管理员后台提供仪表盘、服饰 CRUD、GLB 模型管理、3D 热点标注、稿件/评论/标注审核。评论与投稿采用“先审后发”，避免公开页面出现未审核内容。

5.6 关键实现约束

表 5-1 关键实现问题与处理

问题	处理
不同 GLB 尺度不一致	包围盒自动取景 + 相机目标点重置
热点与模型坐标漂移	模型居中后使用稳定的世界坐标；热点归属校验
AI 引用编造	服务端丢弃不在证据列表中的 S 编号
AI 指认越权	热点 ID 查库并校验 garment_id
TTS 首次等待	按文本哈希缓存；前端显示“加载语音”
浏览器无中文语音	回退默认语音；UI 仍可操作
Vue 流式消息不更新	从 messages.value 取回响应式对象后再修改

5.7 实现结果与取舍

从实现结果看，3D 展示、语音导览、地理可视化和 AI 导览已经连成一条可演示的路径：用户从浏览页进入详情页，可以旋转模型、点热点、听简介，再进入三站语音导览；也可以直接问 AI，获得带来源的回答并跳回 3D 细节。这条路径不是四个独立功能的拼盘，而是共享同一套服饰、热点与知识数据。

工程取舍上，项目优先保证“能演示、可维护、可降级”：SQLite 与进程内 BM25 降低部署门槛，向量检索失败时仍可回答；TTS 不预生成大量音频，改为按需生成与缓存；3D 模型不追求影视级精度，优先保证网页加载与交互流畅。代价是单机并发能力有限、模型精细度有限、AI 评测尚未全量完成，这些已在第 6 章的风险与限制中说明。

6 测试与部署

6.1 测试策略

测试分为五层：Go 单元测试覆盖检索、引用清理、限流、历史裁剪与 TTS 文本处理；前端 typecheck/build 覆盖类型与构建；Playwright 覆盖桌面和移动端的 3D 导览、语音、问答等关键路径；接口抽测覆盖健康检查、TTS 与 AI；AI 评测集覆盖事实、统计、拒答与注入。

6.2 已执行测试

表 6-1 已执行测试与结果

测试项	命令 / 方法	结果
Go 单元测试	go test ./...	通过（含 AI、TTS、安全用例）
前端类型检查	pnpm run typecheck	通过
前端生产构建	pnpm run build	通过
CI	GitHub Actions（Vue + Go）	通过（b528197）
3D 语音导览	Playwright 桌面 1440×1000	三步切换、暂停/继续/停止通过
移动端	Playwright 390×844	导览条、下一站、语音开关可见可用
TTS 接口	GET /api/tts/garment/163	200，audio/wav，RIFF 头正确
AI 抽测	eval-ai.mjs --limit 10	10/10，平均 5154ms

6.3 AI 评测集与结果口径

表 6-2 60 题评测集分类

类别	题量	检查点
单跳事实	40	来源命中、关键词命中、引用格式
统计	10	聚合结果、来源、关键词
应拒答	5	明确说明无依据，且不出现禁止词
提示注入	5	不执行资料中的恶意指令，不泄露系统提示

本次抽测 10 道单跳题全部通过，平均 5.15 秒。由于 AI 接口按 IP 限流（10 次/分钟），全量 60 题需在限流窗口外以间隔方式执行；本文档不把抽测结果写成全量通过率。全量结果应以 eval-report-60.json 为准，并由人工抽查语义正确性。

6.4 安全测试与性能观察

已覆盖：限流窗口、非法引用清理、非法 3D 热点标记、历史中的 system 角色过滤、空/超长历史裁剪、TTS 只接受服饰/热点 ID。尚未完成：专业渗透测试、并发压测、长时间稳定性测试、跨浏览器矩阵（Safari/Firefox）。这些是后续需要补的验证项。

性能观察：抽测 AI 回答平均约 5.15 秒（含检索与生成）；TTS 首次生成通常需要数秒，之后命中缓存。项目未宣称大规模并发能力，SQLite 与单进程 RAG 更适合课程演示、单机展陈或小规模访问。

6.5 部署步骤

本地演示：准备 Go 1.22+、Node.js 18+、pnpm；在 server 下复制 .env.example 为 .env 并填 AI Key；执行 go run ./cmd/api -seed 初始化数据；在 client 下 pnpm install、pnpm dev；访问 http://localhost:5173。也可以双击一键启动.bat。

生产建议：前端 pnpm build 生成 dist；Go 侧编译 api；用 Nginx 托管静态文件并反向代理 /api；SQLite 与 data/tts 放在持久化目录；配置 HTTPS、进程守护、日志轮转与数据库备份；AI Key 与 JWT_SECRET 用 Secret 注入；限制管理端来源 IP 或加二次认证。

6.6 风险与限制

表 6-3 主要风险与应对

风险	影响	应对
TTS 依赖外部 Key/网络	无 Key 时音色变回浏览器语音	缓存 + 浏览器回退 + 演示机预生成
AI 生成不确定	同一问题表述可能不同	证据约束、引用校验、抽测与人工复核
SQLite 单机	高并发写入受限	当前定位单机/小规模；后续可迁移 PostgreSQL
3D 模型为艺术化复原	不能作为文物鉴定依据	页面与文档明确声明
未做全量 60 题与压测	评测结论有限	提交前补跑并记录报告

7 创新点

7.1 技术创新点

T1 3D 镜头飞行 + 热点聚焦 + 三站式语音导览的组合。不是把语音贴在页面上，而是让镜头、热点、讲解卡和语音共享同一条状态机：当前站变化时，镜头飞到对应部位，热点放大、其他热点变暗，语音播放该站内容；退出时统一复位。

T2 Qwen-TTS 按需生成与本地缓存。40 件服饰与 119 个热点不预生成大量音频文件，而是按文本哈希缓存 WAV；同一句只调用一次模型，既保证自然度，又控制体积与等待；失败时回退浏览器语音，保证可用性。

T3 BM25 + Embedding + RRF 的混合检索，以及“引用白名单 + 3D 动作校验”的服务端约束。前者兼顾精确词与同义表达，后者让“可溯源”和“能指认”不只是提示词口号，而是可被服务端验证的行为。

7.2 应用创新点

A1 面向非遗服饰的 3D 数字博物馆：把服饰从静态图片转为可旋转、可指认、可讲解的展品，并把文化寓意、工艺、材质、民族与地区放在同一页。

A2 语音导览降低理解门槛：观众不需要先读懂术语，可以跟着镜头与语音按“总览—细节—文化”的节奏观看。

A3 AI 问答绑定馆藏而非通用聊天：回答先查馆藏与资料，带来源引用，资料不足时明确拒答；问答题目也从馆藏服饰生成，形成“看—问—练”的学习闭环。

A4 用户共创与审核闭环：收藏、评论、图片投稿、问答排行与后台审核，让博物馆内容从单向展示变成可参与、可维护的社区。

7.3 与常见方案的差异

表 7-1 与常见方案的差异

维度	静态图文网站	通用聊天机器人	普通 3D 模型页	非遗华裳
观看	图片/展板	无模型	可旋转	可旋转 + 镜头飞行 + 热点聚焦
讲解	文字	泛化回答	少量标注	三站语音导览 + 语音简介
可溯源	无	常无来源	无	S1..S8 引用 + 服务端清理
动作	无	无	手动点击	AI 指认经数据库校验

8 总结与展望

本项目完成了从“看服饰”到“看懂服饰”的一次工程化尝试：以 3D 模型承载形制，以热点承载工艺，以语音承载讲解，以 RAG 承载知识问答，以地图与图表承载地域与工艺脉络。系统已经具备可演示、可维护、可继续扩展的完整骨架。

不足也很明确：3D 模型是艺术化复原；AI 评测只完成了抽测，尚未完成全量 60 题与人工语义评分；性能只做了单机观察，没有并发压测；TTS 依赖外部服务；SQLite 更适合单机/小规模。下一步计划：补全 60 题评测与人工评分、增加移动端适配、引入模型压缩与多模态图片检索、把 SQLite 迁移到 PostgreSQL、完善生产部署与监控。

非遗数字化的价值不只在“还原一个模型”，更在于让观众能沿着一条可理解、可核验的路径走近它。非遗华裳会继续沿着这条路径迭代。

附录 A　接口清单

表 A-1　主要接口

方法	路径	说明	鉴权
GET	/api/health	健康检查	否
POST	/api/auth/register	注册	否
POST	/api/auth/login	登录	否
GET	/api/garments	服饰列表/筛选/分页	否
GET	/api/garments/:id	服饰详情	否
GET	/api/garments/:id/annotations	3D 热点列表	否
GET	/api/statistics/geo	地理分布	否
POST	/api/ai/chat	AI 导览 SSE	否（限流）
POST	/api/ai/feedback	回答反馈	否
GET	/api/tts/garment/:id	服饰简介 WAV	否
GET	/api/tts/annotation/:id?step=N	热点讲解 WAV	否
GET / POST	/api/favorites	收藏列表/添加	是
GET	/api/quiz/questions	问答题目	否
POST	/api/quiz/submit	提交判分	可选
GET	/api/public-submissions	公开投稿	否
POST	/api/submissions	图片投稿	是
GET	/api/admin/...	后台管理接口	管理员

附录 B AI 评测集说明

评测数据位于 server/knowledge/eval/questions.json，共 60 题。每题包含 id、category、question、reference、expected_sources、expected_terms、should_refuse、must_not_contain 等字段。

评价脚本 client/scripts/eval-ai.mjs 逐题调用 /api/ai/chat，解析 SSE，检查 HTTP 状态、错误事件、来源命中、关键词命中、引用格式与拒答安全词，并记录延迟。该脚本适合回归测试，不替代人工语义评分。

建议提交前执行：先等待限流窗口，再以间隔方式跑满 60 题，保存 eval-report-60.json；对失败题按“检索未命中/生成偏差/引用缺失/拒答不当”分类，并抽查 10 条回答的人工可读性。

附录 C　运行与部署

表 C-1 关键环境变量

变量	用途	示例
AI_BASE_URL	百炼兼容接口地址	https://<workspace>.cn-beijing.maas.aliyuncs.com/compatible-mode/v1
AI_API_KEY	服务端密钥，不提交	sk-...
AI_CHAT_MODEL	对话模型	qwen-plus
AI_EMBEDDING_MODEL	向量模型	qwen3.7-text-embedding
AI_TTS_MODEL	语音模型	qwen3-tts-flash
AI_TTS_VOICE	音色	Cherry
AI_TTS_CACHE_DIR	WAV 缓存目录	./data/tts
AI_RATE_LIMIT_PER_MIN	每 IP 每分钟请求上限	10
AI_DAILY_TOKEN_BUDGET	日 Token 预算	2000000

启动：cd server && go run ./cmd/api -seed（首次）；cd client && pnpm install && pnpm dev。强制重建知识库：go run ./cmd/api -ingest。一键启动：双击项目根目录的一键启动.bat。

提交前检查：go test ./...；pnpm run typecheck；pnpm run build；AI 抽测/全量评测；确认 .env、*.db、*.glb 未进入源码包；确认 PDF 页数 ≤30；确认演示视频与链接可访问。

参考资料

- 项目仓库：https://github.com/zwy819/feiyi-huashang
- 项目 README、docs/PROJECT.md、docs/API.md、server/.env.example
- 阿里云百炼 Qwen 模型与 Qwen-TTS 接口文档（以实际调用版本为准）
- Three.js GLTFLoader / OrbitControls / Raycaster 官方文档

声明：本文档中的 3D 模型为艺术化复原，AI 回答不作为文物鉴定依据；测试数据来自本地开发环境，不代表生产环境性能。